РОССИЙСКИЙ УНИВЕРСИТЕТ ДРУЖБЫ НАРОДОВ

Факультет физико-математических и естественных наук

Кафедра математического моделирования и искусственного интеллекта

ОТЧЕТ ПО КОНТРОЛЬНОЙ РАБОТЕ № 4

Дисциплина: Методы машинного обучения

Студент: Маслова Анастасия

Группа: НКНбд-01-21

Москва 2024

Вариант №14

1. Набор данных: diamonds

2. Независимые признаки: depth, table

3. Метка класса: color

4. Показатель бинарной классификации:

FN (False Negatives) - число точек в положительном классе, ошибочно спрогнозированных в отрицательный класс

5. Параметры нейронных сетей:

Кол-во скрытых слоев: 3

Кол-во нейронов в слое: 128

Оптимизаторы: Adadelta, AdamW, RMSprop

Функция активации в скрытых слоях: leaky_relu

Решение:

1. Загрузите заданный в индивидуальном задании набор данных из Tensorflow Datasets, включая указанные в задании независимые признаки и метку класса. Оставьте в наборе признаки, принимающие числовые значения.

```
import numpy as np
import matplotlib.pyplot as plt
import pandas as pd
import tensorflow as tf
import tensorflow_datasets as tfds
import scipy as sp
from sklearn.model_selection import train_test_split
import scipy
from sklearn.metrics import roc_auc_score
import math
```

```
ds = tfds.load("diamonds", split="train")
df = tfds.as_dataframe(ds)
df.head()
```

→	features/carat	features/clarity	features/color	features/cut	features/depth	features/tal
(1.26	2	4	2	60.599998	6
•	0.80	3	4	4	62.099998	5
2	0.56	4	2	4	61.700001	5
3	3 1.51	3	6	1	64.000000	5
4	U 33	8	5	1	E2 200001	>

Все принимают числовые значения, ничего не трогаем.

2. Визуализируйте точки набора данных на плоскости с координатами, соответствующими двум независимым признакам, отображая точки различных классов разными цветами. Подпишите оси и рисунок, создайте легенду для классов набора данных.

```
np.unique(df['features/color'])
```

```
\Rightarrow array([0, 1, 2, 3, 4, 5, 6])
```

```
x_out = df[['features/table','features/depth']]
df_z = x_out.apply(scipy.stats.zscore)
z_score = 2.5
df2_out = df[((df_z \ge -z_score).sum(axis=1)==2) & ((df_z <= z_score).sum(axis=1)==2))]
perc = df2_del.shape[0]/x_out.shape[0]*100
print(f'Процент выбросов = {perc}%')
Ту Процент выбросов = 3.7096774193548385%
df = df2_out
for i in range(7):
   df_tmp = df.loc[df['features/color'] == i]
   plt.scatter(df_tmp['features/table'], df_tmp['features/depth'], label='feature/color=' + str(i))
plt.xlabel('features/carat')
plt.ylabel('features/depth')
plt.title('Диаграмма рассеяния независимых признаков различных классов метки')
plt.legend();
     Диаграмма рассеяния независимых признаков различных классов метки
           65
          64
          63
        features/depth
          62
          61
                    feature/color=0
```

3. Если признак с метками классов содержит более двух классов, то объедините некоторые классы, чтобы получить набор для бинарной классификации. Объединяйте классы таким образом, чтобы положительный и отрицательный классы были сопоставимы по количеству точек.

62

60

feature/color=1

feature/color=2 feature/color=3 feature/color=4

feature/color=5 feature/color=6

56

58

features/carat

60

59

58

52

df['features/color'].value_counts()

df0 = pd.concat([df0, df_tmp])

df_tmp['features/color'] = 1
df1 = pd.concat([df1, df_tmp])
df_gen = pd.concat([df0, df1])

df_tmp = df.loc[df['features/color'] == i]

for i in range(3, 7):

df_gen

features/color

₹

```
3 10990
1 9457
2 9175
4 8000
0 6566
5 5205
6 2679
Name: count, dtype: int64

df0 = pd.DataFrame()
df1 = pd.DataFrame()
for i in range(3):
    df_tmp = df.loc[df['features/color'] == i]
    df_tmp['features/color'] = 0
```

<ipython-input-8-e94c1629d51b>:5: SettingWithCopyWarning:
 A value is trying to be set on a copy of a slice from a DataFrame.
 Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user_guide/

df_tmp['features/color'] = 0

<ipython-input-8-e94c1629d51b>:10: SettingWithCopyWarning:

A value is trying to be set on a copy of a slice from a DataFrame.

Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user_guide/jdf_tmp['features/color'] = 1

	features/carat	features/clarity	features/color	features/cut	features/depth	features
25	0.50	3	0	3	62.799999	
31	0.60	1	0	3	61.299999	
44	0.71	1	0	4	61.000000	
49	1.01	2	0	4	61.400002	
51	0.31	5	0	4	60.900002	
53858	2.00	2	1	3	62.200001	
53892	2.14	3	1	2	62.799999	
53897	2.10	6	1	3	61.299999	
53907	0.75	1	1	4	60.799999	
53932	2.02	3	1	4	62.000000	
52072 rows × 10 columns						

df_gen['features/color'].value_counts()

features/color

1 26874

0 25198

Name: count, dtype: int64


 $\label{eq:df_train} $$ df_gen[['features/table', 'features/depth', 'features/color']] $$ df_train $$$

_				
→		features/table	features/depth	features/color
	25	58.0	62.799999	0
	31	61.0	61.299999	0
	44	56.0	61.000000	0
	49	59.0	61.400002	0
	51	57.0	60.900002	0
	53858	59.0	62.200001	1
	53892	57.0	62.799999	1
	53897	58.0	61.299999	1
	53907	57.0	60.799999	1
	53932	56.0	62.000000	1

52072 rows × 3 columns

```
df_0 = df_train.loc[df['features/color'] == 0]
df_1 = df_train.loc[df['features/color'] == 1]
plt.figure(figsize=(12,8))
plt.scatter(df_0['features/table'], df_0['features/depth'])
plt.scatter(df_1['features/table'], df_1['features/depth'])
```

54



56

4. Разбейте набор данных из двух признаков и бинарных меток класса на обучающую и тестовую выборки. Постройте нейронные сети с нормализующим слоем и параметрами, указанными в индивидуальном задании, для бинарной классификации и обучите их на обучающей выборке, контролируя процесс обучения нейронных сетей. Определите нейронную сеть с более высоким качеством бинарной классификации по показателю бинарной классификации, указанному в индивидуальном задании.

60

62

Показатель бинарной классификации:

FN (False Negatives) - число точек в положительном классе, ошибочно спрогнозированных в отрицательный класс

58

Параметры нейронных сетей:

Кол-во скрытых слоев: 3

52

Кол-во нейронов в слое: 128

Оптимизаторы: Adadelta, AdamW, RMSprop

Функция активации в скрытых слоях: leaky_relu


```
def plot_loss(history):
  plt.plot(history.history['loss'], label='loss')
  plt.plot(history.history['val_loss'], label='val_loss')
  plt.xlabel('Эпохи обучения')
  plt.ylabel('Ошибка')
  plt.legend()
  plt.grid(True)
x_train, x_test, y_train, y_test = train_test_split(df_gen[['features/table', 'features/depth']], df_gen['features/color'], test_size=0.3, random_stat
normalizer = tf.keras.layers.Normalization()
normalizer.adapt(x_train)
def FN(y_true, y_predict):
    assert len(y_true) == len(y_predict)
    return np.sum((y_{true} == 1) & (y_{predict} == 0))
model_1 = tf.keras.Sequential([
    normalizer,
    tf.keras.layers.Dense(128, activation = 'leaky_relu'),
    tf.keras.layers.Dense(128, activation = 'leaky_relu'),
    tf.keras.layers.Dense(128, activation = 'leaky_relu'),
    tf.keras.layers.Dense(1, activation = 'sigmoid')
])
```

```
loss = 'binary_crossentropy',
   optimizer=tf.optimizers.Adadelta(learning_rate=0.01),
   metrics=[tf.keras.metrics.BinaryAccuracy(name='accuracy')]
history1 = model_1.fit(
   x_train, y_train,
   epochs=20,
   verbose=1,
   validation_split = 0.2)

→ Epoch 1/20
    912/912 [=================] - 4s 3ms/step - loss: 0.6949 - accuracy: 0.4930 - val_loss: 0.6937 - val_accuracy: 0.5110
    Epoch 2/20
    912/912 [==
               ============================== ] - 3s 4ms/step - loss: 0.6916 - accuracy: 0.5264 - val_loss: 0.6928 - val_accuracy: 0.5158
    Epoch 3/20
    912/912 [=================] - 3s 3ms/step - loss: 0.6912 - accuracy: 0.5291 - val_loss: 0.6927 - val_accuracy: 0.5178
    Epoch 4/20
    912/912 [==
                   :============] - 2s 3ms/step - loss: 0.6910 - accuracy: 0.5284 - val_loss: 0.6927 - val_accuracy: 0.5200
    Epoch 5/20
    912/912 [===================] - 2s 3ms/step - loss: 0.6909 - accuracy: 0.5294 - val_loss: 0.6927 - val_accuracy: 0.5193
    Epoch 6/20
    912/912 [=====================] - 2s 3ms/step - loss: 0.6909 - accuracy: 0.5308 - val_loss: 0.6926 - val_accuracy: 0.5193
    Fnoch 7/20
    912/912 [====================] - 3s 3ms/step - loss: 0.6908 - accuracy: 0.5300 - val_loss: 0.6926 - val_accuracy: 0.5195
    Epoch 8/20
    912/912 [===
                      ==========] - 3s 3ms/step - loss: 0.6908 - accuracy: 0.5303 - val_loss: 0.6925 - val_accuracy: 0.5198
    Epoch 9/20
    912/912 [======
                   Epoch 10/20
    912/912 [================] - 2s 3ms/step - loss: 0.6907 - accuracy: 0.5304 - val_loss: 0.6925 - val_accuracy: 0.5203
    Epoch 11/20
    912/912 [==================] - 6s 6ms/step - loss: 0.6907 - accuracy: 0.5298 - val_loss: 0.6924 - val_accuracy: 0.5203
    Fnoch 12/20
    912/912 [=================] - 5s 5ms/step - loss: 0.6906 - accuracy: 0.5299 - val_loss: 0.6924 - val_accuracy: 0.5199
    Epoch 13/20
    912/912 [===
                    Epoch 14/20
    912/912 [===
              Epoch 15/20
    912/912 [=================] - 2s 3ms/step - loss: 0.6906 - accuracy: 0.5313 - val_loss: 0.6924 - val_accuracy: 0.5206
    Epoch 16/20
    912/912 [===================] - 3s 3ms/step - loss: 0.6905 - accuracy: 0.5314 - val_loss: 0.6924 - val_accuracy: 0.5198
    Fnoch 17/20
    912/912 [======
                   Epoch 18/20
    912/912 [======
                   ============] - 2s 3ms/step - loss: 0.6905 - accuracy: 0.5308 - val_loss: 0.6924 - val_accuracy: 0.5207
    Epoch 19/20
    912/912 [===
                     :===========] - 2s 3ms/step - loss: 0.6905 - accuracy: 0.5309 - val_loss: 0.6924 - val_accuracy: 0.5230
    Epoch 20/20
    912/912 [==================] - 2s 3ms/step - loss: 0.6905 - accuracy: 0.5319 - val_loss: 0.6924 - val_accuracy: 0.5203
```

plot_loss(history1)

model_1.compile(




```
model_2 = tf.keras.Sequential([
    normalizer,
    tf.keras.layers.Dense(128, activation = 'leaky_relu'),
    tf.keras.layers.Dense(128, activation = 'leaky_relu'),
    tf.keras.layers.Dense(128, activation = 'leaky_relu'),
    tf.keras.layers.Dense(1, activation = 'sigmoid')
])
```

```
loss = 'binary_crossentropy',
  optimizer=tf.optimizers.AdamW(learning_rate=0.01),
  metrics=[tf.keras.metrics.BinaryAccuracy(name='accuracy')]
history2 = model_2.fit(
  x_train, y_train,
  epochs=20,
  verbose=1,
   validation_split = 0.2)

→ Epoch 1/20
   912/912 [=================] - 4s 3ms/step - loss: 0.6943 - accuracy: 0.5174 - val_loss: 0.6945 - val_accuracy: 0.5134
   Epoch 2/20
   912/912 [==
                 =========== ] - 2s 3ms/step - loss: 0.6941 - accuracy: 0.5132 - val_loss: 0.6939 - val_accuracy: 0.5154
   Epoch 3/20
   912/912 [======
                 Epoch 4/20
   912/912 [==
                  Epoch 5/20
   912/912 [===================] - 2s 3ms/step - loss: 0.6931 - accuracy: 0.5156 - val_loss: 0.6932 - val_accuracy: 0.5158
   Epoch 6/20
   Fnoch 7/20
   912/912 [====================] - 2s 3ms/step - loss: 0.6951 - accuracy: 0.5094 - val_loss: 0.7076 - val_accuracy: 0.5152
   Epoch 8/20
   912/912 [===
                    =========] - 3s 3ms/step - loss: 0.6954 - accuracy: 0.5111 - val_loss: 0.6932 - val_accuracy: 0.5007
   Epoch 9/20
                  ===========] - 3s 4ms/step - loss: 0.6940 - accuracy: 0.5138 - val_loss: 0.6930 - val_accuracy: 0.5154
   912/912 [===
   Epoch 10/20
   912/912 [======
                 Epoch 11/20
                 912/912 [======
   Fnoch 12/20
   912/912 [==================] - 2s 3ms/step - loss: 0.6955 - accuracy: 0.5135 - val_loss: 0.6931 - val_accuracy: 0.5154
   Epoch 13/20
   912/912 [===
                   ==========] - 2s 3ms/step - loss: 0.6942 - accuracy: 0.5135 - val_loss: 0.6928 - val_accuracy: 0.5154
   Epoch 14/20
   912/912 [===
             Epoch 15/20
   912/912 [==================] - 2s 3ms/step - loss: 0.6944 - accuracy: 0.5154 - val_loss: 0.6969 - val_accuracy: 0.5151
   Epoch 16/20
   912/912 [====
             =============================== ] - 2s 3ms/step - loss: 0.6951 - accuracy: 0.5128 - val_loss: 0.6929 - val_accuracy: 0.5154
   Fnoch 17/20
   912/912 [=====
                  ===========] - 2s 3ms/step - loss: 0.6946 - accuracy: 0.5148 - val_loss: 0.7258 - val_accuracy: 0.5089
   Epoch 18/20
   912/912 [======
                   ==========] - 2s 3ms/step - loss: 0.6946 - accuracy: 0.5102 - val_loss: 0.6940 - val_accuracy: 0.5154
   Epoch 19/20
   912/912 [===
                    =========] - 3s 3ms/step - loss: 0.6940 - accuracy: 0.5130 - val_loss: 0.6933 - val_accuracy: 0.5055
   Epoch 20/20
   912/912 [==================] - 3s 3ms/step - loss: 0.6938 - accuracy: 0.5102 - val_loss: 0.6974 - val_accuracy: 0.5154
```

plot_loss(history2)

model_2.compile(




```
model_3 = tf.keras.Sequential([
    normalizer,
    tf.keras.layers.Dense(128, activation = 'leaky_relu'),
    tf.keras.layers.Dense(128, activation = 'leaky_relu'),
    tf.keras.layers.Dense(128, activation = 'leaky_relu'),
    tf.keras.layers.Dense(1, activation = 'sigmoid')
])
```

```
optimizer=tf.optimizers.RMSprop(learning_rate=0.01),
   metrics=[tf.keras.metrics.BinaryAccuracy(name='accuracy')]
history3 = model_3.fit(
   x_train, y_train,
   epochs=20,
   verbose=1.
   validation_split = 0.2)
→ Epoch 1/20
    912/912 [=================] - 3s 3ms/step - loss: 0.6950 - accuracy: 0.5161 - val_loss: 0.6927 - val_accuracy: 0.5165
    Epoch 2/20
    912/912 [==
              ============================== ] - 4s 4ms/step - loss: 0.6938 - accuracy: 0.5158 - val_loss: 0.6933 - val_accuracy: 0.5160
    Epoch 3/20
    912/912 [=================] - 3s 3ms/step - loss: 0.6934 - accuracy: 0.5202 - val_loss: 0.6953 - val_accuracy: 0.5160
    Epoch 4/20
    912/912 [==
                Epoch 5/20
    912/912 [===================] - 2s 2ms/step - loss: 0.6938 - accuracy: 0.5202 - val_loss: 0.6939 - val_accuracy: 0.4896
    Epoch 6/20
    Fnoch 7/20
    912/912 [====================] - 2s 2ms/step - loss: 0.6944 - accuracy: 0.5208 - val_loss: 0.6927 - val_accuracy: 0.5170
    Epoch 8/20
    912/912 [===
                     ==========] - 3s 3ms/step - loss: 0.6939 - accuracy: 0.5203 - val_loss: 0.6966 - val_accuracy: 0.5170
    Epoch 9/20
    912/912 [===
                   Epoch 10/20
    912/912 [================] - 2s 2ms/step - loss: 0.6947 - accuracy: 0.5201 - val_loss: 0.6980 - val_accuracy: 0.4845
    Epoch 11/20
    912/912 [=====================] - 2s 2ms/step - loss: 0.6951 - accuracy: 0.5187 - val_loss: 0.6927 - val_accuracy: 0.5144
    Fnoch 12/20
    912/912 [==================] - 2s 2ms/step - loss: 0.6948 - accuracy: 0.5195 - val_loss: 0.6926 - val_accuracy: 0.5169
    Epoch 13/20
    912/912 [===
                    =================== - 2s 3ms/step - loss: 0.6959 - accuracy: 0.5169 - val_loss: 0.6934 - val_accuracy: 0.5156
    Epoch 14/20
    912/912 [================] - 3s 4ms/step - loss: 0.6954 - accuracy: 0.5200 - val_loss: 0.6940 - val_accuracy: 0.5158
    Epoch 15/20
    912/912 [==================] - 2s 2ms/step - loss: 0.6955 - accuracy: 0.5175 - val_loss: 0.6927 - val_accuracy: 0.5166
    Epoch 16/20
    912/912 [===================] - 2s 2ms/step - loss: 0.6969 - accuracy: 0.5230 - val_loss: 0.6936 - val_accuracy: 0.5139
    Fnoch 17/20
    912/912 [============================= ] - 2s 2ms/step - loss: 0.6958 - accuracy: 0.5189 - val_loss: 0.6966 - val_accuracy: 0.5069
    Epoch 18/20
    912/912 [======
                    Epoch 19/20
    912/912 [===
                      =============== ] - 3s 3ms/step - loss: 0.6953 - accuracy: 0.5209 - val_loss: 0.6942 - val_accuracy: 0.5174
    Epoch 20/20
    912/912 [==================] - 3s 3ms/step - loss: 0.6966 - accuracy: 0.5176 - val_loss: 0.7015 - val_accuracy: 0.5154
```

plot_loss(history3)

model_3.compile(

loss = 'binary_crossentropy',



```
y_prediction1 = model_1.predict(x_train)
y_pred1 = np.array([1 if prob > 0.5 else 0 for prob in np.ravel(y_prediction1)])
y_prediction2 = model_2.predict(x_train)
y_pred2 = np.array([1 if prob > 0.5 else 0 for prob in np.ravel(y_prediction2)])
y_prediction3 = model_3.predict(x_train)
y_pred3 = np.array([1 if prob > 0.5 else 0 for prob in np.ravel(y_prediction3)])
FN(y_pred1, np.array(y_train)), FN(y_pred2, np.array(y_train)), FN(y_pred3, np.array(y_train))
```


```
1140/1140 [======] - 2s 1ms/step (13531, 17548, 10132)
```

FN - это число ошибочно спрогнозированных точек, поэтому побеждает модель, у которой этот показатель меньше, т.е. третья (model_3).

5. Визуализируйте границы принятия решений построенных нейронных сетей на отдельных рисунках на всем наборе данных из двух признаков и бинарных меток классов.


```
def plot_decision_boundary(model, X, y):
    # Найдем диапазоны изменения по осям и построим сетку
    x_{min}, x_{max} = X[:, 0].min() - 0.1, X[:, 0].max() + 0.1
    y_min, y_max = X[:, 1].min() - 0.1, X[:, 1].max() + 0.1
    xx, yy = np.meshgrid(np.linspace(x_min, x_max, 100),
                         np.linspace(y_min, y_max, 100))
    # Набор данных для прогнозирования
    X_in = np.c_[xx.ravel(), yy.ravel()]
    # Прогноз при помощи обученной модели
   y_pred = model.predict(X_in)
    # Проверка мультиклассовости
    if len(y_pred[1]) > 1:
        # мультиклассовая классификация
       # изменяем форму прогноза для визуализации
       y_pred = np.argmax(y_pred, axis=1).reshape(xx.shape)
    else:
        # бинарная классификация
        y_pred = np.round(y_pred).reshape(xx.shape)
    # Рисуем границу решения
    plt.contourf(xx, yy, y_pred, cmap=plt.cm.RdYlBu, alpha=0.7)
    plt.scatter(X[:, 0], X[:, 1], c=y, s=40, cmap=plt.cm.RdYlBu)
    plt.xlim(xx.min(), xx.max())
    plt.ylim(yy.min(), yy.max())
```

```
plt.title("Весь набор данных, Модель 1")
X = np.array(df_gen[['features/table', 'features/depth']])
y=df_gen['features/color']
plot_decision_boundary(model_1, X=X, y=y)
```




```
plt.title("Весь набор данных, Модель 2")
plot_decision_boundary(model_2, X=X, y=y)
```





```
plt.title("Весь набор данных, Модель 3")
plot_decision_boundary(model_3, X=X, y=y)
```

→ 313/313 [============] - 0s 1ms/step



6. Визуализируйте на одном рисунке ROC-кривые для построенных классификаторов на основе нейронных сетей, вычислите площади под ROC-кривыми методом трапеций или иным методом и создайте легенду с указанием площадей кривых.

```
def true_false_positive(threshold_vector, y_test):
    true_positive = np.equal(threshold_vector, 1) & np.equal(y_test, 1)
    true_negative = np.equal(threshold_vector, 0) & np.equal(y_test, 0)
    false_positive = np.equal(threshold_vector, 1) & np.equal(y_test, 0)
    false_negative = np.equal(threshold_vector, 0) & np.equal(y_test, 1)

    tpr = true_positive.sum() / (true_positive.sum() + false_negative.sum())
    fpr = false_positive.sum() / (false_positive.sum() + true_negative.sum())


    return tpr, fpr

def roc_from_scratch(probabilities, y_test, partitions=100):
    roc = np.array([])
    for i in range(partitions + 1):
        threshold_vector = np.greater_equal(probabilities, i / partitions).astype(int)
        tpr, fpr = true_false_positive(threshold_vector, y_test)
        roc = np.append(roc, [fpr, tpr])

    return roc.reshape(-1, 2)
```

```
plt.figure(figsize=(15,7))
m1 = model_1.predict(X)
m2 = model_2.predict(X)
m3 = model_3.predict(X)
r1 = roc_auc_score(y, m1)
r2 = roc_auc_score(y, m2)
r3 = roc_auc_score(y, m3)
ROC1 = roc_from_scratch(m1.reshape(-1),y,partitions=50)
#plt.scatter(ROC[:,0],ROC[:,1],color='#0F9D58',s=100)
\verb|plt.plot(ROC1[:,0],ROC1[:,1],lw=5, label='Model 1, ROC AUC=' + str(r1)||
ROC2 = roc_from_scratch(m2.reshape(-1),y,partitions=50)
#plt.scatter(ROC[:,0],ROC[:,1],color='#0F9D58',s=100)
plt.plot(ROC2[:,\emptyset],ROC2[:,1],lw=5,\ label='Model\ 2,\ ROC\ AUC='\ +\ str(r2))
ROC3 = roc_from_scratch(m3.reshape(-1),y,partitions=50)
#plt.scatter(ROC[:,0],ROC[:,1],color='#0F9D58',s=100)
plt.plot(ROC3[:,0],ROC3[:,1],lw=5,\ label='Model\ 3,\ ROC\ AUC='\ +\ str(r3))
plt.title('ROC кривая',fontsize=20)
plt.xlabel('Показатель FPR (False Positive Rate)',fontsize=16)
plt.ylabel('Показатель TPR (True Positive Rate)',fontsize=16)
plt.legend();
→ 1628/1628 [============= ] - 2s 1ms/step
     1628/1628 [===========] - 3s 2ms/step
```

```
1628/1628 [===========] - 2s 1ms/step
```



7. Определите исходном наборе данных дополнительный признак, отличный от указанных в задании двух независимых признаков, принимающий непрерывные значения и имеющий максимальную дисперсию.

```
df_std = df_gen[['features/carat','features/x','features/y','features/z','price']].std()
```

df_std


```
features/carat
                      0.470888
features/x
                      1.120620
features/y
                      1.142859
features/z
                      0.704301
price
                   3996.285645
dtype: float32
```

price - признак с наибольшей дисперсией

8. Визуализируйте точки набора данных в трехмерном пространстве с координатами, соответствующими трем независимым признакам, отображая точки различных классов разными цветами. Подпишите оси и рисунок, создайте легенду для классов набора данных.

```
fig = plt.figure(figsize=(10,8))
ax = fig.add_subplot(projection='3d')
for i in range(7):
    df_tmp = df.loc[df['features/color'] == i]
    ax.scatter(df_tmp['features/table'], df_tmp['features/depth'], df_tmp['price'], label='feature/color=' + str(i))
ax.legend();
```





from tensorflow.keras.optimizers import RMSprop

from tensorflow.keras.metrics import Accuracy

Epoch 1/80 798/798 [==

Epoch 2/80 798/798 [==

from tensorflow.keras.losses import CategoricalCrossentropy

9. Разбейте исходный набор данных на обучающую и тестовую выборки. Постройте нейронную сеть для многоклассовой классификации с нормализующим слоем и параметрами, соответствующими лучшей нейронной сети для бинарной классифиации из п.4, и обучите ее на обучающей выборке, контролируя процесс ее обучения.

```
X = df[['features/table', 'features/depth', 'price']]
Y = list(df['features/color'])
for i in range(len(Y)):
    tmp = [0]*7
    tmp[Y[i]] = 1
    Y[i] = tmp
Y = np.array(Y)
X_train, X_test, Y_train, Y_test = train_test_split(X, Y, test_size=0.3, random_state=1)
normalizer = tf.keras.layers.Normalization()
normalizer.adapt(X_train)
model_fin = tf.keras.Sequential([
    normalizer.
    tf.keras.layers.Dense(128, activation = 'leaky_relu'),
    tf.keras.layers.Dense(128, activation = 'leaky_relu'),
    tf.keras.layers.Dense(128, activation = 'leaky_relu'),
    tf.keras.layers.Dense(7, activation = 'sigmoid')
])
model_fin.compile(
    loss = 'categorical_crossentropy',
    optimizer=tf.optimizers.RMSprop(),
    metrics = ['accuracy']
history = model_fin.fit(X_train, Y_train, epochs=80, verbose=1, validation_split = 0.3)
```

=============================== - 2s 3ms/step - loss: 1.8581 - accuracy: 0.2142 - val loss: 1.8537 - val accuracy: 0.2176

Epoch 3/80
798/798 [====================================
Epoch 4/80
798/798 [================================] - 2s 3ms/step - loss: 1.8530 - accuracy: 0.2173 - val loss: 1.8530 - val accuracy: 0.2178
Epoch 5/80
798/798 [====================================
Epoch 6/80
798/798 [===============================] - 4s 5ms/step - loss: 1.8481 - accuracy: 0.2198 - val loss: 1.8597 - val accuracy: 0.2191
Epoch 7/80
798/798 [====================================
Epoch 8/80
798/798 [====================================
Epoch 9/80
798/798 [====================================
Epoch 10/80
798/798 [========================] - 2s 3ms/step - loss: 1.8451 - accuracy: 0.2239 - val_loss: 1.8449 - val_accuracy: 0.2211
Epoch 11/80
798/798 [========================] - 3s 3ms/step - loss: 1.8433 - accuracy: 0.2246 - val_loss: 1.8479 - val_accuracy: 0.2241
Epoch 12/80
798/798 [=========================] - 3s 4ms/step - loss: 1.8419 - accuracy: 0.2264 - val_loss: 1.8485 - val_accuracy: 0.2194
Epoch 13/80
798/798 [========================] - 2s 3ms/step - loss: 1.8414 - accuracy: 0.2224 - val_loss: 1.8439 - val_accuracy: 0.2212
Epoch 14/80
798/798 [====================================
Epoch 15/80
798/798 [====================================
Epoch 16/80
798/798 [====================================
Epoch 17/80 798/798 [====================================
Epoch 18/80
798/798 [====================================
Epoch 19/80
798/798 [====================================
Epoch 20/80
798/798 [====================================
Epoch 21/80
798/798 [====================================
Epoch 22/80
798/798 [====================================
Epoch 23/80
798/798 [===============================] - 2s 3ms/step - loss: 1.8362 - accuracy: 0.2315 - val_loss: 1.8471 - val_accuracy: 0.2243
Epoch 24/80
798/798 [====================================



[67] plot_loss(history)

